

Occupancy Modelle 2 (E6)

Erfassung und Monitoring von Wildtieren (SoSe 2026)

Johannes Signer 

jsigner@uni-goettingen.de

Georg-August Universität Göttingen, Abteilung Wildtierwissenschaften

May 17, 2026

Wo sind wir?

Kurze Wiederholung/Vorschau

particify.rz.tu-bs.de

8587 6183



Hintergrund: Daten

Was wird analysiert:

- Wo kommt eine Tierart vor?
- Welche Kovariaten wirken sich auf
 - das Vorkommen, bzw.
 - das Entdecken


der Art aus. Man möchte herausfinden, welcher Teil eines Gebietes von einer Art genutzt wird.

Was für Daten werden benötigt

- Eine Identifikation des Individuum ist nicht nötig.
- Mehrere Standorte müssen **> 1 Mal** aufgesucht werden.
- Nachweise der Art können aktiv (z.B. visuell) oder passiv (z.B. Losungen oder Spuren) aufgezeichnet werden.
- Die Standorte sollten so gewählt werden, dass sie voneinander unabhängig sind.


Das Vorkommen von Eichhörnchen in der Schweiz

- Als Beispiel wollen wir uns die Verbreitung von Eichhörnchen in der Schweiz ansehen. Dazu wurden an 265 Standorten (1 km^2) zwischen 1 h und 6 h nach Eichhörnchen gesucht.
- Die Standorte wurden dreimal besucht.
- Können wir eine Vorhersage machen, wie viel Prozent der Fläche der Schweiz von Eichhörnchen besetzt sind?




- Digitales Höhen Model (DHM bzw. engl. DEM = Digital Elevation Model) für die Schweiz.


Hier wurde gesucht (236 von 42275 möglichen Quadraten)




Anzahl Sichtungen pro Quadrat




Was beeinflusst das Vorkommen?




Hängt das Vorkommen von der Seehöhe ab?




Einteilung der Seehöhe in Höhenklassen.



Wie sieht das mit Wald aus?




Wir wollen die Belegungsrate ψ von Eichhörnchen in Abhängigkeit von Seehöhe und Waldbedeckung modellieren.



ψ ist hier die Vorkommenswahrscheinlichkeit für Quadrate, mit einem bestimmten Waldanteil und Seehöhe.

Die Anzahl Quadrate für jede Kombination:



Zufällige Einteilung, lieber kontinuierlich modellieren

$$\psi_i = g^{-1}(\beta_0 + \beta_1 * \text{seehöhe}_i + \beta_2 * \text{wald}_i)$$

- ψ_i ist die Belegungsrate, dass ein Standort von einem Eichhörnchen besiedelt ist.
- g^{-1} stellt sicher, dass der Wert von ψ in das Intervall von 0 bis 1 fällt.
- $\beta_0 + \beta_1 * \text{seehöhe}_i + \beta_2 * \text{wald}_i$ beschreibt den Zusammenhang zwischen der Wahrscheinlichkeit ψ_i und den Kovariaten in einer 1 km² großen Zelle.

- Wir passen zwei Modelle an

```
m1 <- glm(y ~ ele + forest, data = sq1, family = binomial())  
m2 <- glm(y ~ ele + I(ele^2) + forest, data = sq1, family = binomial())
```

Im zweiten Modell **m2** haben wir einen quadratischen Term (= Polynom 2. Ordnung) für Seehöhe, dies ermöglicht nicht-lineare Effekte für Seehöhe zu berücksichtigen (z.B. wenn intermediäre Seehöhen bevorzugt werden).


Welches Modell passt am besten zu den Daten?

AIC


Das AIC (Akaike Information Criterion) misst wie gut ein Modell auf die Daten passt. Das AIC hat keine Einheiten und je niedriger der Wert ist, desto besser ist ein Modell.

```
AIC(m1, m2)
```

	df	AIC
m1	3	302.0203
m2	4	297.4976





Damit könnten wir auch eine Vorhersage für die ganze Schweiz machen (m2).



Aber was ist mit den drei Sichtungen?

Ist es immer gleich wahrscheinlich ein Eichhörnchen zu entdecken?





- Occupancymodelle bieten die Möglichkeit die Entdeckungswahrscheinlichkeit (p) und die Belegungsrate (ψ) zusammen zu modellieren.
- p ist meist < 1 und dies impliziert, dass wenn bei einem Besuch kein Individuum einer Art gesehen wurde, kann dies zwei Gründe haben:
 - Kein Individuum war da.
 - Ein oder mehrere Individuen waren präsent, wurden aber nicht gesehen.

Etwas Notation

- Es werden an $i = 1, \dots, R$ Standorten $j = 1, \dots, T$ Aufnahmen durchgeführt.
- $y_{ij} = 1$ wenn ein Individuum der Art bei der i -ten Aufnahme am Standort j gefunden wurde, ansonsten ist $y_{ij} = 0$.

Aufnahme (T=4)

	j = 1	2	3	4
i = 1	0	0	1	0
2	1	1	1	0
3	0	0	1	1
4	0	0	0	1
5	1	0	1	0
6	0	1	0	1

Standort (R=6)

Statistische Modellierung

- Die Modellierung erfolgt in zwei Schritten:
 - Der biologische Prozess: $z_i \sim \text{Ber}(\psi_i)$ (= **state process**)
 - Der Beobachtungsprozess: $y_{ij} \sim \text{Ber}(z_i \times p_{ij})$ (= **observation process**)
- z_i ist eine **latente** Zufallsvariable (d.h., wir können sie nicht direkt beobachten), die angibt ob am Standort i die Art mit der Wahrscheinlichkeit ψ präsent ist oder nicht.
- y_{ij} ist die Beobachtung am Standort i zum Zeitpunkt j . Die Wahrscheinlichkeit, dass ein Individuum beobachtet wird hängt von der Wahrscheinlichkeit ψ (das die Art überhaupt vorkommt) und p (das die Art gesehen) wird ab.
- Die Parameter ψ und p müssen geschätzt werden.

Die Parameter ψ und p können wiederum als Funktion von Kovariaten modelliert werden:

- $\psi_i = g^{-1}(\beta_0 + \beta_1 x_i)$

Das heißt, wir können die Belegungsrate (ψ_i) einer Art am Standort i als lineare Kombination von Kovariaten modellieren. Z.B. könnte es für eine Art wahrscheinlicher sein im Wald als im Offenland vorzukommen.

- $p_{ij} = g^{-1}(\alpha_0 + \alpha_1 x_{ij})$

Das heißt, wir können die Entdeckungswahrscheinlichkeit für eine Art am Standort i zum Zeitpunkt j als lineare Funktion von Kovariaten modellieren. Z.B. können wir die Hypothese aufstellen, dass die Entdeckungswahrscheinlichkeit vom Wetter oder der Tageszeit abhängt.

Eichhörnchen in der Schweiz

Zur Schätzung von ψ und p gibt es das R-Paket [unmarked](#).

Journal of Statistical Software

[Information on Mission](#)

[Information for Authors](#)

[Style Guide](#)

[Volumes ▾](#)

[About ▾](#)

[Home](#) / [Archives](#) / [Vol. 43 \(2011\)](#) / [Issue 10](#)

unmarked: An R Package for Fitting Hierarchical Models of Wildlife Occurrence and Abundance

Ian Fiske, Richard Chandler

Mit der Funktion `occu()` können die Parameter eines Belungsmodells (=Occupancymodells) geschätzt werden. Dafür müssen der Funktion `occu()` zwei Argumente übergeben werden:

Dieser Teil der Formel beschreibt, wie die Entdeckungswahrscheinlichkeit modelliert wird. “~ 1” heißt, dass die Entdeckungswahrscheinlichkeit konstant ist.

`occu(~ 1 ~ seehoehe, data = daten)`

Dieser Teil der Formel beschreibt, wie die Vorkommenswahrscheinlichkeit modelliert wird. “~ seehoehe” heißt, dass die Vorkommenswahrscheinlichkeit von der Seehöhe abhängig ist.

- **formula**: Beschreibt wie das Modell spezifiziert ist. Beispielsweise würde `~ datum ~ seehoehe` bedeuten, dass die Entdeckungswahrscheinlichkeit von Eichhörnchen vom Datum (**datum**) abhängt und die Belegungsrate von der Seehöhe (**seehoehe**). Will man einen Parameter konstant halten (z.B. dass das Vorkommen immer gleich ist), dann schreibt man einfach `~ 1`. Also die Formel `~ datum ~ 1` modelliert die Entdeckungswahrscheinlichkeit abhängig vom Datum (**date**) und eine konstante Belegungsrate (`~ 1`).
- **data**: Ein spezielles **data.frame**, das **unmarkedFrameOccu** genannt wird. Mit der Funktion **unmarkedFrameOccu()** kann so ein **data.frame()** erstellt werden.

Beispiel Eichhörnchen in der Schweiz

```
head(sq0)
```

	spec.name	coordx	coordy	ele	route	forest	det071	det072	det073	date071
1	Squirrel	922942	63276	450	6.2	3	0	0	0	20
2	Squirrel	928942	79276	450	5.5	21	0	0	0	19
3	Squirrel	928942	103276	1050	4.3	32	0	0	0	22
4	Squirrel	934942	95276	950	4.5	9	1	1	0	22
5	Squirrel	934942	111276	1150	5.4	35	0	0	0	15
6	Squirrel	946942	95276	550	3.6	2	0	0	0	21

	date072	date073	dur071	dur072	dur073
1	46	54	230	300	280
2	50	56	180	180	180
3	55	61	175	195	175
4	49	70	300	255	240
5	43	60	180	215	210
6	40	49	200	200	195

- **coordx** und **coordy** sind die Koordinaten.
- **ele**, **route** und **forest** sind die Seehöhe, Transektlänge und Waldbedeckung.
- **det*** gibt an, ob ein Eichhörnchen gesehen wurde (**1**) oder nicht (**0**).

- **date*** ist das Datum an dem das Transekt ausgeführt wurde (Tage seit dem 1.4.).
- **dur*** ist die Länge der Aufnahme.

Variablen skalieren

- In unserem Beispiel sind die Variablen **ele** (Seehöhe) und Waldanteil **forest** sehr unterschiedlich skaliert.
- **ele** hat Werte von 250 bis 2750, während **forest** Werte zwischen 0 und 100 haben kann.
- Diese Unterschiede und die Tatsache, dass **ele** sehr hohe Werte hat, können zu numerischen Problemen führen.
- Variablen werden deshalb häufig Standardisiert, dabei wird der Mittelwert abgezogen und durch die Standardabweichung dividiert.
- Die Variable ist dann um 0 zentriert und erstreckt sich bis zu ± 3 .


```
head(sq$ele)
```

```
[1] 450 450 1050 950 1150 550
```

```
sq$ele_scaled <- (sq$ele - mean(sq$ele)) / sd(sq$ele)
```

```
sq$forest_scaled <- (sq$forest - mean(sq$forest)) / sd(sq$forest)
```

An der Verteilung an sich hat sich **nichts** geändert!



Als erstes muss man einen **unmarkedFrameOccu** erstellen:

```
library(unmarked)
of <- unmarkedFrameOccu(
  y = sq[, c("det071", "det072", "det073")], # R * J Matrix
  siteCovs = sq[, c("ele_scaled", "forest_scaled")],
  obsCovs = list(
    date = sq0[, c("date071", "date072", "date073")],
    dur = sq0[, c("dur071", "dur072", "dur073")]
  )
)
```

Hinweis: Mit der Funktion **list()** können wir unterschiedliche Kovariaten (z.B. **date**) übergeben, für die wir jeweils $R * J$ Beobachtungen haben.

Damit können wir jetzt mit den Kovariaten **ele**, **forest**, **date** und **duration** beliebige Modelle erstellen.

Anpassen eines Models

```
m0 <- occu(  
  ~ 1 # Modell für p  
  ~ ele_scaled + forest_scaled, # Modell für psi  
  data = of)
```

Und ein zweites Modell mit einem quadratischen Effekt für Seehöhe.

```
m1 <- occu(  
  ~ 1 # Modell für p  
  ~ ele_scaled + I(ele_scaled^2) + forest_scaled, # Modell für psi  
  data = of)
```

I(ele^2) heißt, dass wir für die Belegungsrate ψ einen quadratischen Effekt berücksichtigen.

```
summary(m1)
```

Call:

```
occu(formula = ~1 ~ ele_scaled + I(ele_scaled^2) + forest_scaled,  
      data = of)
```

Occupancy (logit-scale):

	Estimate	SE	z	P(> z)
(Intercept)	1.091	0.521	2.09	0.036226
ele_scaled	-0.547	0.276	-1.98	0.047461
I(ele_scaled^2)	-0.930	0.402	-2.31	0.020819
forest_scaled	1.573	0.444	3.54	0.000401


Detection (logit-scale):


Estimate	SE	z	P(> z)
-0.218	0.144	-1.51	0.131

AIC: 739.8842

Number of sites: 265

Was heißt das jetzt?





Und was heißt das für p ? Bis jetzt wurde p konstant gehalten. Gibt es einen Effekt von Jahreszeit (**date**) und Suchdauer (**dur**)?

```
m2 <- occu(  
  ~ dur + date # Modell für p  
  ~ ele_scaled + I(ele_scaled^2) + forest_scaled, # Modell für psi  
  data = of)  
summary(m2)
```

Call:


```
occu(formula = ~dur + date ~ ele_scaled + I(ele_scaled^2) + forest_scaled,  
      data = of)
```

Occupancy (logit-scale):


	Estimate	SE	z	P(> z)
(Intercept)	0.888	0.434	2.05	0.040854
ele_scaled	-0.533	0.259	-2.06	0.039831
I(ele_scaled^2)	-0.805	0.363	-2.22	0.026587
forest_scaled	1.405	0.370	3.80	0.000146

Detection (logit-scale):

	Estimate	SE	z	P(> z)
(Intercept)	-1.13564	0.61612	-1.84	0.0653
dur	0.00561	0.00241	2.33	0.0199
date	-0.00802	0.00525	-1.53	0.1268



Auch die Entdeckungswahrscheinlichkeit kann dargestellt werden:



Welches Modell passt am besten

model	AIC	dAIC
m2	731.4085	0.000000
m1	739.8842	8.475748
m0	744.7076	13.299124

Erweiterungen


Wir haben uns den einfachsten Fall eines Occupancymodells angeschaut. Es gibt zahlreiche Erweiterungen dazu anderen Designs (z.B. mehrere Sessions) oder zum gleichzeitigen modellieren mehrere Arten.

Selbsttest: Occupancy Modelle

Welche Voraussetzungen müssen für eine Occupancyanalyse erfüllt sein?

1. Individuen müssen eindeutig identifizierbar sein.
2. Es muss mindestens eine Aufnahme pro Standort vorhanden sein.
3. Es ist zwingend erforderlich, dass alle Individuen gezählt werden.

Wie interpretieren Sie die folgende Abbildung?



1. Die Belegungsrate nimmt mit zunehmender Distanz zu Wasser ab.
2. Die Belegungsrate wird von der Distanz zu Wasser nicht beeinflusst.
3. Die Entdeckungswahrscheinlichkeit nimmt mit zunehmender Distanz zu Wasser ab.